LAPORAN PRAKTIKUM

IF4071 Pemrosesan Ucapan

Pengenalan Vowel Bahasa Indonesia dengan DTW dan Model Gaussian



Disusun oleh Kelompok 6

Nadhif Radityo Nugroho (13523045)

Aldoy Fauzan Avanza (18223113)

M Rabbani K A (18223130)

Sekolah Teknik Elektro dan Informatika

Institut Teknologi Bandung

Semester I Tahun Akademik 2026/2027

Repositori GitHub:

https://github.com/Rakh2525/DTW_Gaussian-Vowel_Recognition

1. Pendahuluan

Laporan ini membahas pembuatan dan perbandingan dua sistem pengenal vowel Bahasa Indonesia (/a/, /i/, /u/, /e/, /o/) untuk praktikum IF4071 Pemrosesan Ucapan.

Tautan

Item	Tautan
Program	https://github.com/Rakh2525/DTW_Gaussian-Vowel_Recognition/tree/main/src
Data	https://github.com/Rakh2525/DTW_Gaussian-Vowel_Recognition/tree/main/data

Sistem yang dibangun

- **Sistem 1:** *template-based ASR* dengan *Dynamic Time Warping* (DTW) dan *averaged template*.
- **Sistem 2:** model Gaussian (*mean* dan *covariance*), dipilih dengan *negative log-likelihood* terkecil.
- **Fitur:** MFCC 39 dimensi, diimplementasikan dengan Python.

Cara menjalankan (dari root repositori)

```
pip install -r requirement.txt
python src/prepareDataset.py
python src/main.py
python -m unittest discover -s test -v
```

2. Dataset

Setiap anggota merekam lima vowel dua kali. Rekaman 1 menjadi data latih, rekaman 2 menjadi data uji *closed speakers*, dan data *open speakers* berasal dari kelompok lain.

Folder	Isi	Jumlah
`data/template/<vowel>/`	Rekaman 1 tiap *speaker* kelompok (spk1 sampai spk3), data latih	15
`data/test/closed/<vowel>/`	Rekaman 2 tiap *speaker* kelompok	15
`data/test/open/<vowel>/`	Rekaman 17 *speaker* dari G04, G05, G07, dan G11	84

Catatan

- **Jumlah *speaker*:** kelompok hanya memiliki tiga *speaker*, sehingga tiap *template* dibentuk dari tiga rekaman (spesifikasi: lima).
- **Pemetaan *speaker*:** spk1 adalah Aldoy, spk2 adalah Nadhif, dan spk3 adalah Rabbani.
- **Data tidak lengkap:** satu rekaman *open* (G05_S05, vowel /e/) tidak tersedia di Drive, sehingga totalnya 84, bukan 85.
- ***Sample rate*:** spk1 16 kHz, spk2 dan spk3 48 kHz. Semuanya diubah ke 16 kHz *mono*.

3. Metode dan Implementasi

3.1 *Preprocessing*

- **Muat:** rekaman WAV dibaca lalu dinormalisasi ke rentang [-1, 1] bertipe `float64`.
- **Konversi:** audio diubah ke *mono* dan *di-resample* ke 16 kHz.
- **Amplitudo:** dinormalisasi terhadap nilai puncak tiap rekaman, karena *gain* mikrofon tiap *speaker* berbeda jauh.
- **Hening:** bagian awal dan akhir dipangkas dengan RMS *frame* 25 ms, ambang 0,02 setelah normalisasi.

3.2 Ekstraksi fitur MFCC 39 dimensi

Parameter	Nilai
Jendela / geser	25 ms / 10 ms
Koefisien MFCC	13 (c0 diganti log-energi)
Filter *mel* / NFFT	26 / 512
Delta dan *delta-delta*	13 + 13 + 13 = 39 dimensi (lebar 2)
Library	`python_speech_features` (*delta* dihitung sendiri)

- **Tanpa CMVN:** pada vowel statis, rata-rata spektrum membawa informasi vowel itu sendiri.
- **Validasi:** program berhenti bila dimensi fitur bukan 39.

3.3 Sistem 1: DTW dengan *averaged template*

- **Jarak antar *frame*:** Euclidean.
- ***Cost* DTW:** rekursi tiga arah, dinormalisasi dengan panjang jalur.

- ***Template*:** rekaman latih tiap vowel diselaraskan ke rekaman pertama (referensi) dengan DTW, lalu *frame* yang terpetakan ke tiap *frame* referensi dirata-ratakan.
- **Keputusan:** vowel dengan *cost* terkecil.

Pseudo code

```
fungsi DTW(X, T):
    D[i][j] = jarak_euclid(X[i], T[j])
    C[i][j] = D[i][j] + min(C[i-1][j], C[i][j-1], C[i-1][j-1])
    path = backtrack dari (N-1, M-1)
    return C[N-1][M-1] / panjang(path)
fungsi BuatTemplate(rekaman_vowel):
    ref = fitur rekaman pertama
    untuk tiap rekaman lain: align ke ref dengan DTW
    template[k] = rata-rata frame yang terpetakan ke ref[k]
fungsi Kenali(audio):
    X = MFCC39(audio)
    return argmin_v DTW(X, template[v])
```

3.4 Sistem 2: Model Gaussian

- **Model:** satu Gaussian multivariat 39 dimensi per vowel, dengan *mean* dan *covariance* penuh dari seluruh *frame* latih vowel itu.
- ***Ridge*:** `1e-3` ditambahkan ke diagonal *covariance* agar dapat di-invers.
- **Skor:** rata-rata *negative log-likelihood* per *frame*, vowel dengan skor terkecil dipilih.
- **Keterbatasan:** *frame* dianggap independen, sehingga urutan waktu tidak dipakai.

```
NLL(X | v) = rata-rata_t 0.5 * ( 39*log(2*pi) + log|S_v| + (x_t - m_v)' S_v^-1
   (x_t - m_v) )
prediksi = argmin_v NLL(X | v)
```

3.5 Skenario pengujian

Skenario	Data uji	Jumlah
Closed Recording	Rekaman 1 kelompok (sama dengan data latih)	15
Closed Speakers	Rekaman 2 kelompok (*speaker* sama, rekaman berbeda)	15
Open Speakers	*Speaker* kelompok lain (G04, G05, G07, G11)	84
Open (LOSO), tambahan	Satu *speaker* ditahan, model dari dua *speaker* lain, diuji pada kedua rekamannya	30

- **Akurasi:** jumlah prediksi benar dibagi seluruh data uji, dikali 100%.

- **Rata-rata:** rata-rata sederhana tiga skenario utama. LOSO hanya pembanding dan tidak dihitung.

4. Hasil Eksperimen

Tabel 1. Akurasi (%)

Sistem	*Closed Recording*	*Closed Speakers*	*Open Speakers*	Rata-rata
DTW *Template*	100,0	86,7	70,2	85,6
Model Gaussian	100,0	93,3	58,3	83,9

- **Tambahan:** pada skenario LOSO, akurasi DTW 66,7% dan Gaussian 43,3%.

Tabel 2. Akurasi per vowel (%)

Sistem	Skenario	/a/	/i/	/u/	/e/	/o/
DTW *Template*	*Closed Recording*	100,0	100,0	100,0	100,0	100,0
DTW *Template*	*Closed Speakers*	100,0	100,0	66,7	100,0	66,7
DTW *Template*	*Open Speakers*	100,0	82,4	58,8	43,8	64,7
Model Gaussian	*Closed Recording*	100,0	100,0	100,0	100,0	100,0
Model Gaussian	*Closed Speakers*	66,7	100,0	100,0	100,0	100,0
Model Gaussian	*Open Speakers*	52,9	100,0	35,3	31,2	70,6

Tabel 3. Akurasi per *speaker* (%)

Speaker kelompok (skenario *closed*):

Sistem / skenario	spk1	spk2	spk3
DTW, *Closed Recording*	100,0	100,0	100,0
DTW, *Closed Speakers*	100,0	100,0	60,0
Gaussian, *Closed Recording*	100,0	100,0	100,0
Gaussian, *Closed Speakers*	80,0	100,0	100,0

Speaker kelompok lain (*Open Speakers*, 5 data uji per *speaker*, G05_S05 hanya 4):

Speaker	DTW	Gaussian	*Speaker*	DTW	Gaussian
G04_S03	40,0	40,0	G07_S03	100,0	100,0
G04_S04	40,0	20,0	G07_S04	100,0	100,0
G05_S01	60,0	40,0	G07_S05	40,0	40,0
G05_S02	80,0	40,0	G11_S01	40,0	60,0
G05_S03	60,0	60,0	G11_S02	100,0	100,0
G05_S04	80,0	60,0	G11_S03	100,0	80,0
G05_S05	100,0	75,0	G11_S04	80,0	60,0
G07_S01	60,0	60,0	G11_S05	100,0	40,0
G07_S02	20,0	20,0			

Confusion matrix Open Speakers

Baris adalah vowel yang benar, kolom adalah hasil prediksi. DTW *Template*:

benar \ prediksi	a	i	u	e	o
a	17	0	0	0	0
i	0	14	1	0	2
u	0	1	10	0	6
e	2	4	2	7	1
o	4	1	1	0	11

Model Gaussian:

benar \ prediksi	a	i	u	e	o
a	9	6	0	0	2
i	0	17	0	0	0
u	0	5	6	0	6
e	0	10	1	5	0
o	4	1	0	0	12

- **Data lengkap:** *confusion matrix* skenario lain dan seluruh prediksi ada di folder `results` pada repositori.

5. Analisis

- **Catatan:** data uji kecil (15 pada *closed*, 84 pada *open*), satu kesalahan menggeser akurasi *closed* 6,7 poin. Pengaruh averaged template (5.5) dan bias ke /i/ (5.2) diuji pada src/analysis.py (results/analysis.md), sedangkan penyebab lain masih dugaan yang konsisten dengan hasil.

5.1 Perbandingan akurasi

Skenario	DTW (%)	Gaussian (%)	Catatan
Closed Recording	100,0	100,0	Data uji sama dengan data latih, tidak mengukur generalisasi
Closed Speakers	86,7	93,3	Selisih satu data uji (13 dan 14 benar dari 15)
Open Speakers	70,2	58,3	DTW unggul 11,9 poin pada 84 data uji
Rata-rata	85,6	83,9	Hampir sama karena kelebihan Gaussian di *closed speakers* diimbangi kelemahannya di *open*
Open (LOSO), tambahan	66,7	43,3	Pembanding di dalam kelompok

5.2 Mengapa DTW dan Gaussian berbeda

Faktor	DTW	Gaussian
Informasi waktu	Urutan *frame* diselaraskan terhadap *template*	*Frame* dianggap independen, urutan tidak dipakai
Parameter	*Template* rata-rata, tanpa estimasi *covariance*	*Covariance* penuh 39 x 39 (780 parameter independen) per vowel dari sekitar tiga rekaman
Hasil pada *open*	Lebih stabil (70,2%)	*Bias* ke /i/: 39 dari 84 prediksi, padahal data /i/ hanya 17
Normalisasi	*Cost* dibagi panjang jalur	Rata-rata NLL per *frame*

- **Bias ke /i/:** *covariance* /i/ paling besar (log-determinan 34,7 dibanding 22,5 sampai 28,3 pada vowel lain), sehingga model /i/ paling lebar dan memberi likelihood relatif tinggi pada frame vowel lain. Namun /i/ juga punya frame latih terbanyak (275), jadi faktor lain belum bisa disingkirkan.

5.3 Mengapa akurasi *closed* dan *open* berbeda

- ***Closed*:** *template* dan model dibangun dari *speaker* yang sama dengan data uji (*formant*, kecepatan bicara, mikrofon, dan kondisi rekaman sama).
- ***Open*:** *speaker* baru membawa *formant*, *pitch*, perangkat, dan lingkungan rekaman yang tidak terwakili oleh tiga *speaker* latih.
- **Pemberat:** hanya tiga *speaker* latih dan *sample rate* asal yang berbeda.

5.4 Pengaruh perbedaan *speaker*

- **Terbaik:** DTW mengenali sempurna enam *speaker open* (G05_S05, G07_S03, G07_S04, G11_S02, G11_S03, G11_S05).
- **Terburuk:** G07_S02 hanya 20%, sedangkan G04_S03, G04_S04, G07_S05, dan G11_S01 40%.
- ***Closed speakers*:** spk3 paling sulit bagi DTW (60%).
- **LOSO:** *speaker* yang ditahan turun ke 60 sampai 80% (DTW) dan 20 sampai 70% (Gaussian).
- **Penyebab:** aksen, mikrofon, atau kecepatan bicara per *speaker* tidak kami selidiki.

5.5 Pengaruh *averaged template*

- ***Template*:** rata-rata *frame* dari tiga rekaman yang diselaraskan ke rekaman pertama.
- **Hasil:** template rata-rata lebih baik daripada template tunggal. Closed speakers 86,7% dibanding 68,9%, open speakers 70,2% dibanding 60,7% (rata-rata tiga template tunggal).
- **Catatan:** template tunggal spk1 menyamai template rata-rata pada open (70,2%), jadi keuntungan averaging bergantung pada speaker yang dipilih.
- **Kelemahan:** hasil bergantung pada rekaman referensi (urutan penyelarasan DTW): closed speakers 80,0 sampai 100,0% dan open speakers 63,1 sampai 70,2% tergantung referensi. Tiga rekaman juga masih sedikit.

5.6 Kesalahan pengenalan vowel (*Open Speakers*)

Vowel	DTW (%)	Gaussian (%)	Pola kesalahan
/a/	100,0	52,9	Gaussian sering memprediksi /i/
/i/	82,4	100,0	Akurasi Gaussian sebagian akibat *bias* ke /i/
/u/	58,8	35,3	Tertukar dengan /o/ (6 kali pada kedua sistem)

/e/	43,8	31,2	Gaussian: 10 dari 16 ke /i/. DTW: ke /i/, /a/, dan /u/
/o/	64,7	70,6	Tertukar dengan /a/ (4 kali) dan /u/

6. Kesimpulan

- **Implementasi:** kedua sistem berhasil dibangun sesuai spesifikasi: MFCC 39 dimensi, DTW dengan *averaged template*, dan model Gaussian dengan *negative log-likelihood*.
- ***Closed*:** *closed recording* 100% pada kedua sistem (tidak menguji generalisasi). *Closed speakers*: Gaussian 93,3% dan DTW 86,7%, selisih satu data uji.
- ***Open*:** DTW (70,2%) lebih baik daripada Gaussian (58,3%). Rata-rata tiga skenario: DTW 85,6% dan Gaussian 83,9%.
- **Faktor utama:** perbedaan *speaker*, dengan akurasi per *speaker open* 20 sampai 100%.
- **Kesalahan:** /e/ tersulit, /u/ dan /o/ paling sering tertukar, Gaussian *bias* ke /i/.
- **Keterbatasan:** tiga *speaker* latih (spesifikasi lima), data uji *closed* hanya 15, penyebab per speaker (aksen, mikrofon) belum diuji.

7. Saran

- **Data:** tambah *speaker* dan rekaman latih agar *covariance* Gaussian stabil dan *template* representatif.
- **Model:** coba *covariance* diagonal, *shrinkage*, atau campuran Gaussian (GMM).
- **Eksperimen:** uji CMVN, pemilihan rekaman referensi, dan metode averaging lain secara terpisah.
- **Perekaman:** seragamkan perangkat dan *sample rate* antar *speaker*.
- **Evaluasi:** laporkan interval kepercayaan atau ulangi dengan pembagian *speaker* berbeda.

8. Kontribusi Anggota

Pembagian kerja anggota kelompok dapat dilihat pada tabel berikut.

Nama	**NIM**	**Kontribusi**
Nadhif Radityo Nugroho	13523045	Merekam data (spk2), implementasi DTW dan *averaged template*, serta menulis bagian Metode DTW dan Analisis
Aldoy Fauzan Avanza	18223113	Merekam data (spk1), implementasi model Gaussian, *pipeline* evaluasi tiga skenario, serta menulis bagian Hasil Eksperimen
M Rabbani K A	18223130	Merekam data (spk3), *preprocessing* dan ekstraksi MFCC 39 dimensi, *unit test*, pengumpulan data *open speaker*, serta menulis Pendahuluan, Kesimpulan, dan Saran